

Artificiell Intelligens - Kunskapskontroll

I denna kunskapskontroll ska du först besvara nedanstående teoretiska frågor och sedan bygga en AI-modell. Ni kommer att kunna välja mellan att modellera MNIST eller att fritt välja ett projekt. Notera att det alltså är två delar som ska genomföras.

Uppgiften görs och lämnas in individuellt men ni uppmuntras till att samarbeta och diskutera med varandra så länge som det ni lämnar in är ert eget arbete, precis som i arbetslivet.

På denna kunskapskontroll kan man få betygen IG / G / VG. För att bli godkänd så skall du visa att du använder koncepten vi lärt oss korrekt. Att uppnå godkänt är i sig inte "enkelt" och kräver ansträngning. Satsar du på VG så förbered dig på att det blir mer arbete och kräver djupare förståelse samt problemlösning (se exakta betygskriterier i kursplanen).

Börja så snart som möjligt för att snabbt upptäcka vad som kommer att vara utmanande samt kommunicera med varandra för att få tips.

Du ska lämna in både kod samt en rapport och genomföra en muntlig presentation av ditt arbete. Läs dokumentet "rapport_guide" för att se hur en rapport skall skrivas och använd mallen "rapport_mall" när du skriver din rapport. Om du inte kan delta vid lektionstillfälle för att göra en muntlig presentation kommer du att behöva spela in dig själv när du presenterar. Max 15 minuter.

Du ska även genomföra en självutvärdering där du besvarar följande tre frågor:

1. Har något varit utmanande i kursen/kunskapskontrollerna? Om ja, hur har du hanterat det?
2. Vilket betyg anser du att du ska ha och varför?
3. Något du vill lyfta fram till Terese?

Ladda upp dina lösningar i en mapp (repository) på GitHub. Glöm inte att göra mappen "public" så att jag kan komma åt filerna. Lämna in en GitHub-länk i Uppgifter på Teams.

Deadline: Fredag 15 maj 2026 kl. 23.59.

Del 1 - Teoretiska frågor

Denna del syftar till att vi ska börja tänka på vissa grundläggande och centrala koncept inom maskininlärning som är en central del inom AI. Svara gärna kort och koncist. Inkludera svaren som ett sista avsnitt i din rapport.

1. Förklara vad AI, ML respektive DL är och relationen mellan begreppen.
2. Julia delar upp sin data i träning och test. På träningsdatan så tränar hon tre modeller; "Linjär Regression", "Lasso regression" och en "Random Forest modell". Hur skall hon välja vilken av de tre modellerna hon skall fortsätta använda när hon inte skapat ett explicit "valideringsdataset"?
3. Vad är "regressionsproblem? Kan du ge några exempel på modeller som används och potentiella tillämpningsområden?
4. Antag att vi har följande regressionsmodell: $Y = \beta_0 + \beta_1 X + \varepsilon$, vad kallas Y , X , β_i och ε ?
5. Hur kan du tolka RMSE och vad används det till?

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

6. Vad är "klassificeringsproblem? Kan du ge några exempel på modeller som används och potentiella tillämpningsområden?
7. Vad är en "Confusion Matrix"?
8. Hur definieras Precision? Hur tolkas Precision?
9. Hur definieras Recall? Hur tolkas Recall?
10. Göran påstår att datan antingen är "ordinal" eller "nominal". Julia säger att detta måste tolkas. Hon ger ett exempel med att färger såsom {röd, grön, blå} generellt sett inte har någon inbördes ordning (nominal) men om du har en röd skjorta så är du vackrast på festen (ordinal) – vem har rätt?
11. Vad är skillnaden mellan parametrar och hyperparametrar i en maskininlärningsmodell? Ge ett exempel på varje och förklara varför de inte kan optimeras på samma sätt.
12. Förklara skillnaden mellan overfitting och underfitting i en maskininlärningsmodell. Beskriv även hur man kan upptäcka respektive åtgärda dem.
13. Hur funkar OvO och OvR algoritmerna?
14. Vad är intuitionen bakom att regularisera en modell?
15. Vad är Bias Variance Trade-off?
16. Varför är mer komplexa modeller inte alltid bättre?

17. Kan du kort förklara hur fixa men okända parametrarna $\beta_0, \beta_1, \dots, \beta_p$ skattas med hjälp av MSE?
18. I frågan ovan, varför används MSE och inte RMSE? Vad är skillnaden?
19. Vad betyder övervakad respektive oövervakad maskininlärning?
20. Vad är prediktions- respektive konfidensintervall? Vilket intervall är bredast och varför?

Del 2 – Skapa en AI-modell

Alternativ 1: Modellera MNIST

MNIST är ett standarddataset inom maskininlärning som används för att träna och testa algoritmer för bildigenkänning.

Det består av 70 000 gråskalebilder av handskrivna siffror (0–9), där varje bild är 28×28 pixlar. Datasetet är uppdelat i ett träningsset och ett testset och används ofta som ett första exempel när man lär sig klassificering, neurala nätverk och djupinlärning.

Skapa en ML-modell (G)

Använd maskininlärning för att modellera MNIST-datan. Du skall utvärdera minst tre olika modeller i ditt arbete och göra ett komplett ML-flöde, från början där du laddar in data till slut där du utvärderar den bäst valda modellen på din testdata.

Hur du laddar ned MNIST-datan kan du se här:

```
1 import numpy as np
2 from sklearn.datasets import fetch_openml

1 mnist = fetch_openml("mnist_784", version = 1, cache = True, as_frame = False)
2 print(mnist.DESCR)

1 X = mnist["data"]
2 y = mnist["target"]
```

Skapa en Streamlit-applikation (VG)

De som satser på VG behöver bygga en applikation för att prediktera ”ny data”.

Kolla följande video om Streamlit: <https://www.youtube.com/watch?v=ggDaRzPP7A&list=PLgzaMbMPEHEX9Als3F3sKKXexWnyEKH45&index=12>

Skapa en Streamlit-applikation där man med hjälp av en modell tränad på MNIST (kan vara den modell som du arbetat med i del 1) kan prediktera ”ny data” som matas in via Streamlit. Den ”nya datan” kan t.ex. komma från att användaren laddar upp en egen hand-ritad bild, att man ritar en siffra via Streamlit eller att man tar en bild via kameran på datorn. Du väljer själv.

Notera, generellt sett är utmaningen att man behöver transformera bilderna som tas innan de används för att skapa en prediktion.

Exempel för inspiration: [Lägg upp | LinkedIn](#)

Alternativ 2: Välj ett eget projekt (G/VG)

I detta alternativ får ni fritt välja vilket projekt ni vill arbeta med. Detta är en fin möjlighet att prova idéer och dessutom kunna diskutera dessa med klasskamrater och utbildare.

Tillämpa något vi lärt oss (ML, neurala nätverk, chattbotar, ...) på riktig data. Data kan exempelvis vara data som är kopplad till något du arbetar med eller är intresserad av eller data som finns tillgängligt på exempelvis Kaggle: <https://www.kaggle.com/datasets>. Kaggle har mycket intressant data inom en rad olika områden. Kika så kommer du säkert hitta något som intresserar dig. Om det du vill göra är för omfattande kanske du kan göra ett steg på vägen, exempelvis någon form av "proof of concept"?

Notera, detta är ett projekt där ni är väldigt flexibla i att välja omfattning och ambitionsnivå.

De som väljer detta alternativ kan kontakta Terese för att presentera sin idé och diskutera betygskriterier.